

Board Game Rules Assistant

ระบบถาม-ตอบกฎบอร์ดเกมจากคู่มือจริง พร้อมอ้างอิงไฟล์และเลขหน้า

จัดทำโดย

นาย กรวิชญ์ มณีรัตน์ รหัสนักศึกษา 66070234

เสนอ

ดร. ณัฏฐ์ ดิลกธนากุล

รายงานนี้เป็นส่วนหนึ่งของรายวิชา

06016475 SPECIAL TOPICS IN INFORMATION TECHNOLOGY 3

หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาเทคโนโลยีสารสนเทศ

คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

บทคัดย่อ

การถกเถียงเรื่องกฎระหว่างเล่นบอร์ดเกมทำให้เกมต้องหยุดชะงัก และคำตอบของข้อถกเถียง นั้นมักอยู่ในย่อหน้าเดียวบนหน้าใดหน้าหนึ่งของคู่มือซึ่งผู้เล่นไม่สะดวกเปิดค้นในระหว่างเกม รายงานนี้นำเสนอ Board Game Rules Assistant ซึ่งเป็นระบบถาม-ตอบที่ตอบคำถามเรื่องกฎ จากคู่มือจริงเป็นภาษาปกติ พร้อมระบุชื่อไฟล์และเลขหน้าที่เป็นแหล่งที่มาของคำตอบ เพื่อให้ผู้ใช้ตรวจสอบย้อนกลับได้ด้วยตนเอง คลังข้อมูลที่ใช้คือคู่มือของเกม Wingspan จำนวนสี่เล่ม ได้แก่ คู่มือหลัก ภาคเสริม Asia ภาคผนวกความสามารถนก และกฎสำหรับเล่นคนเดียว รวม 44 หน้า

ระบบแบ่งข้อความที่สกัดจากคู่มือออกเป็นส่วนย่อยตามขอบเขตย่อหน้า ขนาด 450 คำ ซ้อนทับกัน 90 คำ ได้ทั้งสิ้น 74 ส่วน โดยแต่ละส่วนเก็บชื่อไฟล์และเลขหน้ากำกับไว้ แล้วแปลงเป็นเวกเตอร์ด้วยแบบจำลอง bge-m3 ค้นคืนด้วยค่าความคล้ายแบบโคไซน์ และกำหนดเกณฑ์คะแนนขั้นต่ำไว้ที่ 0.45 เพื่อให้ปฏิเสธการตอบเมื่อไม่พบหลักฐานเพียงพอ แทนการคาดเดาคำตอบ รายการอ้างอิงสร้างจากส่วนข้อความที่ถูกค้นคืนมาจริงด้วยโปรแกรม ไม่ได้แยกจากข้อความที่แบบจำลองสร้างขึ้น และการค้นคืนถูกห่อให้อยู่ในรูปเครื่องมือ ที่แบบจำลองเลือกเรียกใช้เองได้ เพื่อให้การค้นเป็นการตัดสินใจตามลักษณะของคำถาม

การประเมินผลใช้ชุดคำถามที่ผู้จัดทำกำกับคำตอบด้วยตนเองจำนวน 24 ข้อ แบ่งเป็นคำถามที่มี คำตอบอยู่ในคลังข้อมูล 20 ข้อ และคำถามที่คลังข้อมูลไม่มีคำตอบ 4 ข้อ โดยวัดด้วยค่า recall@4 precision@4 และ MRR เทียบกับเกณฑ์อ้างอิงสองแบบ คือการสุ่มและการค้นแบบ คำสำคัญด้วย BM25 ผลการทดลองพบว่าการค้นคืนด้วยเวกเตอร์ได้ค่า recall@4 เท่ากับ 0.683 ขณะที่ BM25 ได้ 0.400 และการสุ่มได้ 0.050 นอกจากนี้ได้ทดลองปรับขนาดส่วนย่อยของเอกสาร จำนวนหกรูปแบบบนชุดคำถามเดียวกัน พบว่าการเปลี่ยนจากขนาด 300 คำซ้อนทับ 45 คำ เป็น 450 คำซ้อนทับ 90 คำ ทำให้ค่า recall@4 เพิ่มขึ้นจาก 0.533 เป็น 0.683 และค่า MRR เพิ่มขึ้นจาก 0.512 เป็น 0.642 ทั้งนี้การเทียบคำตอบที่กำกับไว้ใช้วิธีเปรียบเทียบด้วยตัวข้อความ แทนการอ้างอิงด้วยรหัสของส่วนย่อย เนื่องจากรหัสดังกล่าวเปลี่ยนความหมายทันทีที่มีการ แบ่งส่วนใหม่

ผลการทดลองยังแสดงข้อจำกัดที่ยังแก้ไม่ได้สองประการ ประการแรกคือการปฏิเสธการตอบ ซึ่งระบบปฏิเสธได้ถูกต้องเพียง 1 ข้อจากคำถามที่ไม่มีคำตอบ 4 ข้อ เนื่องจากช่วงคะแนนของ คำถามทั้งสองกลุ่มทับซ้อนกัน จึงไม่มีเกณฑ์คะแนนใดที่แยกออกจากกันได้ ประการที่สองคือ กรณีที่ระบบให้คำตอบซึ่งถูกต้องตามหลักฐานที่ค้นเจอแต่ไม่ครบถ้วน เพราะข้อยกเว้นของกฎ ข้อนั้นไม่ถูกค้นคืนขึ้นมา ทั้งที่มีอยู่จริงในคลังข้อมูล และการปรับขนาดส่วนย่อยที่ทำให้ค่า recall สูงขึ้นดังกล่าวข้างต้น คือสาเหตุที่ทำให้ข้อยกเว้นนั้นถูกค้นพบได้ยากขึ้น

คำสำคัญ: retrieval-augmented generation, การประเมินผลการค้นคืน, agent, การอ้างอิงแหล่งที่มา, บอร์ดเกม

1 ปัญหา และผู้ใช้

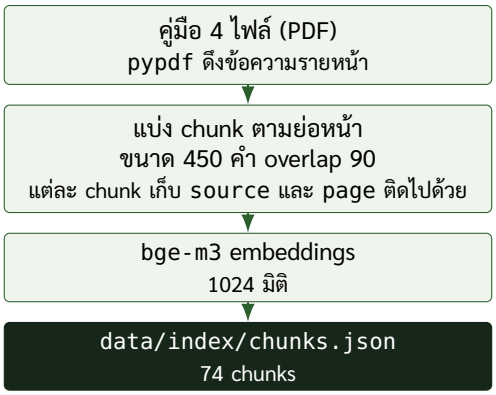
การเถียงกันเรื่องกฎทำให้เกมหยุด คนหนึ่งมั่นใจว่าวางไข่บนรังที่เต็มแล้วไม่ได้ อีกคนมั่นใจว่าได้ และคำตอบอยู่ในย่อหน้าเดียว หน้าเดียว ของคู่มือที่ไม่มีใคร อยากเปิดหาตอนที่อีกสี่คนรออยู่

Board Game Rules Assistant ตอบคำถามนั้นเป็นภาษาปกติ แล้วอ้างอิงชื่อไฟล์และเลขหน้า เพื่อให้คนที่โต๊ะเปิดตรวจแล้วเล่นต่อได้ ระบบนี้ออกแบบมาสำหรับคนสองแบบ: ผู้เล่นกลางเกมที่ต้องการคำตัดสินภายในสามสิบวินาที และคนที่กำลังสอนเกมที่ตัวเองจำได้ครึ่งเดียว

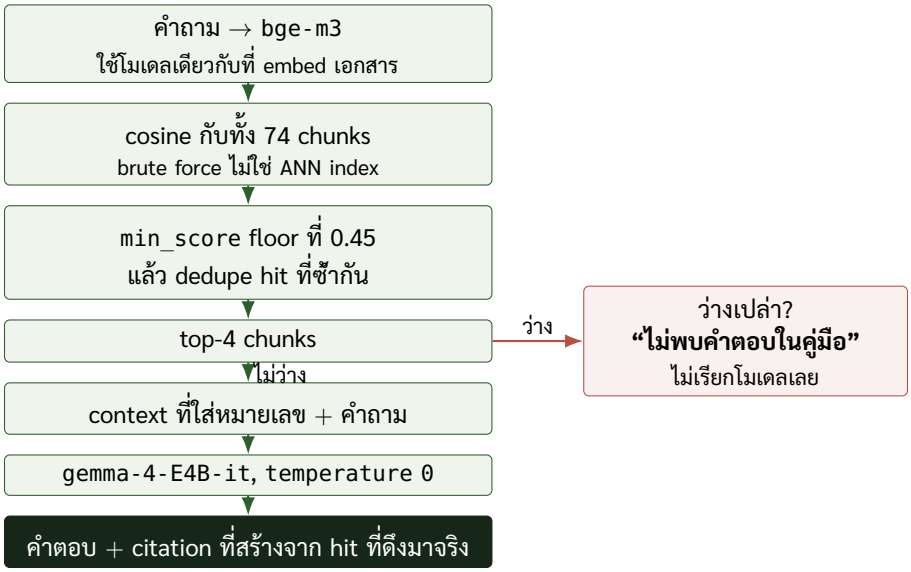
คลังข้อมูลคือคู่มือ Wingspan สี่เล่ม ได้แก่ คู่มือหลัก, Asia expansion, ภาคผนวกความสามารถนก และกฎเล่นคนเดียว (Automa) ที่เลือกเกมนี้เพราะคำถามเรื่องกฎ ของมันมีคำตอบที่ถูกต้องพิมพ์อยู่ในหน้าใดหน้าหนึ่งจริง ผลลัพธ์จึงตรวจสอบได้ — citation ที่ผิดจะเห็นว่าผิดทันที และการสร้างชุดข้อมูลประเมินผลที่ label เองก็ทำได้ ด้วยต้นทุนต่ำ ส่วน Asia expansion ถูกเลือกแทนภูมิภาคอื่นเพราะเป็นภาคที่ผู้เล่น กลุ่มเป้าหมายมีอยู่จริง

2 การออกแบบ

2.1 ไปป์ไลน์

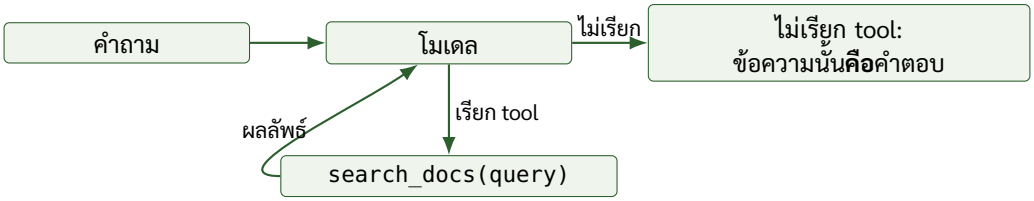


รูปที่ 1: การสร้าง index แบบออฟไลน์ (`scripts/ingest.py`)



รูปที่ 2: ขั้นตอนตอนรับคำถาม ถ้าผลการค้นว่างเปล่า ระบบจะหยุดก่อนถึงโมเดล

เส้นทางของ agent (`src/rag/agent.py`) ใช้ retriever ตัวเดียวกัน แต่ห่อให้เป็น tool



รูปที่ 3: agent loop: วนได้ไม่เกิน `max_steps` และในก้าวสุดท้ายจะถอน tool ออกเพื่อบังคับให้ตอบ

2.2 กลุ่มความสามารถทั้งสาม และเหตุผลที่เลือกสามกลุ่มนี้

กลุ่ม	อยู่ที่ไหน	ทำไม
Retrieval / RAG	`src/rag/`	เป้าหมายทั้งหมดคือคำตอบที่ยึดกับหน้าใดหน้าหนึ่งจริง ไม่ใช่ความจำของโมเดลเกี่ยวกับ Wingspan
การประเมินผล retrieval	`eval/`	ขนาด chunk, `top_k` และ `min_score` เป็นแค่การเดา จนกว่าจะมีอะไรมาวัด การประเมินผลเกิดขึ้นก่อนการปรับจูน และเปลี่ยนสิ่งที่ถูกสร้างขึ้นจริง
Agent loop ที่มี tool	`src/rag/agent.py`	การค้นหนึ่งครั้งต่อหนึ่งคำถามทำให้เสียการค้นไปกับคำว่า “thanks” และกู้คืนจากการค้นครั้งแรกที่พลาดไม่ได้ เมื่อทำเป็น tool การค้นจึงเป็นการตัดสินใจของโมเดล

ส่วนติดต่อแบบ served interface (FastAPI/SSE) ถูกตัดออกจากขอบเขต การทำการประเมินผลให้เสร็จอย่างถูกต้องมีค่ามากกว่าการมีกลุ่มที่สี่แบบทำค้างไว้ครึ่งเดียว

2.3 การตัดสินใจที่ต้องอธิบายได้

- **ใช้ cosine แบบ brute force ไม่ใช่ ANN index** — 74 chunks สแกนจบในระดับมิลลิวินาที index แบบประมาณค่าคือความซับซ้อนที่ซื้อมาก่อนจำเป็น
- **ใช้ embedding model ตัวเดียวทุกที่** — vector จากคนละโมเดลเทียบกันไม่ได้ ดังนั้น `bge-m3` จึง embed ทั้งเอกสารและคำถาม และชื่อโมเดลถูกเก็บไว้ใน metadata ของ index
- **citation สร้างจากโค้ดของเราเอง จาก hit ที่ retrieval ดึงมาจริง** — ไม่ได้แกะจากข้อความที่โมเดลเขียน โมเดลสร้าง chunk id ปลอมในข้อความได้ แต่มันเอา id นั้นเข้าไปอยู่ในรายการ source ไม่ได้
- **ไม่เรียกโมเดลเมื่อ retrieval ไม่พบอะไรเลย** — การป้อน context ว่างให้โมเดลแล้วหวังว่ามันจะปฏิเสธเอง คือช่องทางที่ทำให้เกิดคำตอบมั่ว ๆ ที่ดูมั่นใจ ไม่มีหลักฐาน ก็ไม่ตอบ
- **`temperature=0` ทุกจุด** เพื่อให้ตัวเลขทุกตัวในรายงานนี้ทำซ้ำได้

3 การประเมินผล

3.1 ชุดคำถามทดสอบ

คำถาม 24 ข้อ label ด้วยมือเทียบกับคลังข้อมูล

	จำนวน
ตอบได้ (บันทึก gold chunk ไว้)	20
ตอบไม่ได้ (ต้องไม่คืนอะไรเลย)	4

คำถามที่ตอบไม่ได้ไม่ใช่ตัวถ่วง มันเป็นสิ่งเดียวที่วัดว่าเส้นทาง “ไม่รู้” ทำงานหรือไม่ และเป็นจุดที่ระบบนี้อ่อนที่สุด (หัวข้อ 5.1)

คำถามถูกเขียนแบบที่ผู้เล่นพูด ไม่ใช่แบบที่คู่มือเขียน โดยสี่ข้อเป็นการถอดความกฎที่ คลังข้อมูลมีอยู่จริงโดยตั้งใจ เพราะนั่นคือจุดที่ dense retrieval ควรชนะการจับคู่คำ และการตัดคำถามแบบนี้ออกจะเป็นการเข้าข้าง BM25

bias ของการ label และสิ่งที่ทำเพื่อลดมัน chunk ที่เป็นตัวเลือกถูกจัดอันดับด้วย retriever ตัวเดียวกับที่กำลังถูกประเมิน label จึงเอนไปทางสิ่งที่มันหาเจออยู่แล้ว เพราะ chunk ที่มันไม่เคยแสดงก็ label ไม่ได้ จึงมีการป้องกันสองอย่างใน `scripts/label.py` คือคำสั่ง `/find` ที่แสดง ตัวเลือกด้วย BM25 แทน และการพิมพ์ chunk id ใดก็ได้ไม่ว่ามันจะถูกเสนอมาหรือไม่ ทั้งสองอย่างถูกใช้จริง bias ลดลงแต่ไม่ได้หายไป ส่วนคำถามที่ถูกตัดทิ้งเพราะไม่มี chunk ไหนตอบได้ บันทึกไว้ใน `eval/skipped.txt` และอภิปรายในหัวข้อ 5.2

3.2 Metric ที่ใช้

recall@4 วัดว่าจาก chunk ที่ควรถูกดึงมา มีกี่อันที่อยู่ภายใน cutoff ที่ prompt ใช้จริง **precision@4** วัดว่าสิ่งที่โมเดลถูกบังคับให้อ่านมีประโยชน์กี่ส่วน และ **MRR** วัดว่า chunk ที่ถูกต้องอันแรกอยู่อันดับที่เท่าไรโดยไล่ดูทั้งอันดับ ไม่หยุดที่ cutoff สองค่าหลังไม่ตรงกันโดยตั้งใจ เพราะ recall ถามว่า “อยู่ใน cutoff ไหม” ส่วน MRR ถามว่า “อยู่สูงแค่ไหนในภาพรวม” รายงานทั้งคู่เพราะ chunk ที่หาไม่เจอ กับ chunk ที่ถูกฝังอยู่ลึก เป็นคนละปัญหากัน

3.3 Baseline

baseline	ใช้ทดสอบอะไร
random (กำหนด seed)	พื้นอ้างอิง ถ้าระบบจริงชนะการสุ่มไม่ได้ ก็ไม่ต้องอ่านอย่างอื่นต่อ
BM25	คู่แข่งที่สมเหตุสมผล: IDF $\times$ saturating TF $\times$ length penalty เอาชนะไม่ได้เมื่อเจอ token เฉพาะที่ตรงตัว แต่มองไม่เห็นคำพ้องความหมาย

3.4 ผลลัพธ์

74 chunks, $k = 4$, คำถามที่ตอบได้ 20 ข้อ

ระบบ	recall@4	precision@4	MRR
random (พื้นอ้างอิง)	0.050	0.025	0.067
BM25 (keyword)	0.400	0.212	0.254
`bge-m3` (vector)	**0.683**	**0.350**	**0.642**

vector retrieval ชนะการสุ่ม 14 เท่า และชนะ BM25 1.7 เท่าในด้าน recall ตัวเลข 0.400 ของ BM25 ไม่ใช่ผลที่อ่อน และหัวข้อ 4.1 แสดงคำถามที่ BM25 ชนะขาด

ทำซ้ำได้ด้วย `uv run --env-file .env python -m eval.run_eval`

3.5 การปรับปรุงที่วัดได้: ขนาดของ chunk

ค่าเริ่มต้นแบบไม่คิดมากคือ chunk ตามย่อหน้าขนาด 300 คำ overlap 15% ซึ่งเลือกตามสไลด์ ไม่ได้มาจากหลักฐาน จึงกวาดทดสอบหกค่าบนคำถามชุดเดียวกัน โดยไม่เปลี่ยนอย่างอื่นเลย

config	chunks	recall@4	precision@4	MRR
paragraph 300/45 (ค่าเริ่มต้น)	111	0.533	0.275	0.512
fixed 300/0	99	0.583	0.275	0.508
paragraph 300/0	108	0.558	0.250	0.492
paragraph 450/90	**74**	**0.683**	**0.350**	**0.642**
paragraph 600/120	59	0.683	0.312	0.642
paragraph 200/40	160	0.558	0.312	0.533

recall@4: 0.533 $\rightarrow$ 0.683 (+0.150) **MRR: 0.512 $\rightarrow$ 0.642 (+0.130)**

มีสองเหตุผลที่ทำให้ตัวเลขนี้น่าเชื่อถือ

450 เป็นจุดยอด ไม่ใช่ค่าที่ใหญ่ที่สุดที่ลอง chunk ขนาด 600 คำให้ recall เท่ากันเป๊ะ แต่เสีย precision ($0.350 \rightarrow 0.312$) เส้นโค้งราบแล้วเริ่มมีต้นทุน นั่นคือเหตุผลที่เลือกใช้ 450 แทนที่จะเป็นเลขที่ใหญ่ที่สุดในตาราง

วิธีวัดทำงานต้านผู้ชนะ เฉลยถูกเทียบด้วยข้อความไม่ใช่ chunk id เพราะ id ไม่มีความหมายทันทีที่ chunking เปลี่ยน — ถ้าเทียบด้วย id ทุกแถวในตารางจะถูกให้คะแนนเทียบกับ passage ที่ผิด โดยที่ไม่มีอะไรฟ้องเลย กติกาการเทียบด้วยข้อความถือว่าเฉลยถูกพบ เมื่อ chunk ที่ดึงมามีเนื้อหาครอบคลุมเฉลยนั้นเป็นส่วนใหญ่ ซึ่งเอื้อ chunk ขนาดเล็ก: เฉลยที่ถูกตัดเป็นสามท่อนนับว่าพบ ถ้าดึงท่อนใดท่อนหนึ่งขึ้นมาได้ แต่ config ที่ชนะมีจำนวน chunk น้อยเป็นอันดับสองของตาราง bias จึงดึงไปทางตรงข้าม ค่า $+0.150$ จึงเป็นการประเมินที่ต่ำกว่าความจริง

นี่ไม่ใช่การเดาแล้วฟลุก สมมติฐานมาจาก chunk ที่สังเกตเห็นตอน label ซึ่งประกาศว่า “powers fall into 3 categories” แล้วกลับมีอยู่แค่สองแบบ — แบบที่สามถูกตัดไปอยู่ chunk ถัดไป (หัวข้อ 4.4)

4 การวิเคราะห์: จุดที่ล้มเหลว

รายละเอียดเต็มพร้อมคำสั่งสำหรับทำซ้ำอยู่ใน `eval/FAILURE_CASES.md`

4.1 dense retrieval พลาดสิ่งที่ BM25 หาเจอ

คำถามสามข้อที่เขียนแบบที่ผู้เล่นพูด

คำถาม	ผลที่ได้
“Can I play a bird in any habitat I want?”	เฉลยไม่อยู่ใน vector top-10 แต่ BM25 เจอที่อันดับ 3
“Where am I allowed to put a new bird?”	เฉลย passage เดียวกัน พลาดอีกครั้ง
“What do I do when my turn comes around?”	top-10 ไม่มี chunk จากคู่มือหลักเลยสักอัน

ข้อที่สามชัดที่สุด: คำว่า “turn” ไปจับกับ “Automa’s Turn”, “Once Between Turns” และ “turn order dial” — ความหมายผิดทุกอัน

นี่คือเหตุผลที่วัดได้สำหรับการทำ hybrid search ไม่ใช่การเดา

4.2 expansion เบียดคู่มือหลักออกไป

คำถาม “How does the first player token move between rounds?” คืน chunk จาก Asia expansion มา 8 จาก 10 อัน และคำตอบ (คู่มือหลักหน้า 5) ไม่อยู่ในนั้น Asia มีสัดส่วน 34% ของ chunk ทั้งหมดและเขียนกฎของเกมหลักซ้ำด้วยถ้อยคำที่เกือบเหมือนกัน chunk ที่คล้ายกันหลายอันจึงแย่งช่องเดียวกันและดันต้นฉบับออกไป

4.3 ข้อเท็จจริงที่ไม่มีอยู่ใน chunk ไหนเลย

เมื่อถูกถามว่า “What is the Duet map?” ระบบตอบว่ามันใช้ “for exactly **2 players**” แต่ไม่มี chunk ไหนระบุจำนวนผู้เล่นของ Duet mode — ยืนยันแล้วด้วยการ label คำถามข้อนั้นตรง ๆ แล้วไม่พบเฉลย ข้ออ้างนั้นจึงมาจากน้ำหนัก ในตัวโมเดลเอง ทั้งที่ prompt ที่สั่งให้ยึดกับ context, floor ของคะแนน และรายการ citation ทำงานถูกต้องในทุกจุดอื่น คำว่า “Use ONLY the context” ชี้นำโมเดลได้ แต่มัดมันไม่ได้

4.4 รายการที่ถูกตัดขาดตรงรอยต่อของ chunk

chunk หนึ่งเปิดด้วย “Powers on bird cards fall into 3 categories” แล้วอธิบายแบบ brown กับ pink จากนั้นก็จบ ส่วน white อยู่ใน chunk ถัดไป โดยมีข้อความของการ์ดนกคั่นกลาง ซึ่งเกิดจากการที่ PDF สองคอลัมน์ ถูกอ่านสลับเข้ามาในเนื้อความ เมื่อถามว่า white power คืออะไร retrieval จัดอันดับ chunk ที่ประกาศว่ามีสามแบบไว้อันดับหนึ่ง — ซึ่งเป็นอันที่ไม่ได้นิยามแบบที่กำลังถูกถามถึง

เรื่องนี้คือที่มาของการกวาดค่า chunking ในหัวข้อ 3.5

4.5 ถูกทุกอย่าง ยกเว้นไม่ครบ — เคสล้มเหลวที่ใช้ demo

> **ถาม:** Can a bird power let me go over my egg limit?
> **ตอบ:** No, no power allows you to lay more eggs on a bird than its limit allows `[c0009]`

คลังข้อมูลมีทั้งกฎทั่วไป (ภาคผนวกหน้า 8: ไม่มีความสามารถใดเกินลิมิตไข่ได้) และ การ์ดของ Asia expansion (หน้า 12: “You may go 2 over its egg limit”) agent ดึง chunk มาสี่อัน ทั้งหมดอยู่หน้า 8 จากสามไฟล์ (คู่มือหลักซ้ำสองอัน) และไม่มีอันไหนเป็นข้อยกเว้นเลย

ไม่มีอะไรในคำตอบที่เป็นเท็จ citation ก็ถูกต้องสำหรับ passage ที่มันอ่าน แต่ผู้เล่นที่ทำตามคำตอบนี้ยังเล่นผิดกฎอยู่ดี และ citation ก็ไม่ได้ให้เหตุผลใดที่จะทำให้เขาสงสัย

ทำไมข้อยกเว้นถึงเข้าถึงไม่ได้ และหัวข้อ 3.5 แลกมาด้วยอะไร ข้อยกเว้นอยู่ใน index จริง — `c0040`, Asia หน้า 12 ยืนยันด้วยการค้นข้อความใน chunk ตรง ๆ มีสอง query ที่ดึงมันขึ้นมาไม่ได้ รวมถึง query ที่สร้างจากถ้อยคำของ passage นั้นเอง: query ที่มีวลี “2 over its egg limit” ไม่คืน chunk ที่มีวลี “2 over its egg limit” chunk นั้นเปิดด้วยเรื่อง tucking และการนับแถว แล้วค่อยไปถึงกฎเรื่องไข่กลาง ๆ ทาง embedding เพียงตัวเดียวของมันจึงถูกครอบงำ ด้วยเนื้อหาที่มันขึ้นต้น

ภายใต้ index แบบเก่า 300/45 กฎข้อนั้นเคยอยู่ที่หัว chunk ของตัวเอง โดยไม่ถูกเจือจาง **การเปลี่ยน chunking ที่ทำให้ recall@4 ขึ้น 0.150 คือสิ่งที่ฝังมันลงไป** การกวาดค่าวัดค่าเฉลี่ยจากคำถาม 20 ข้อ จึงมองไม่เห็นเรื่องนี้ การปรับปรุงเป็นเรื่องจริง และมันไม่ฟรี

4.6 ขยะจากการแปลงไฟล์ผ่าน floor ของคะแนนได้

เมื่อถูกถามว่า “thanks, that helped!” เส้นทางที่ไม่ใช่ agent ดึง chunk ที่ได้คะแนน **0.458** ซึ่งสูงกว่า floor ที่ 0.45 โดยเนื้อหาของ chunk นั้นคือ metadata ของการ export จาก InDesign (`WS_EE_BirdSwiftStart_r4.indd 1 6/9/21 4:19 PM`) ระบบบอกได้ถูกต้องว่าหาคำตอบไม่พบ แต่กลับพิมพ์ chunk ขยะอันนั้นเป็น Source ไว้ข้างล่าง ซึ่งบั๊กการแสดงผลนี้แก้แล้ว ส่วนพฤติกรรมของ retrieval ปล่อยไว้ตามเดิม เพราะเป็นหลักฐานเกี่ยวกับ floor และคลังข้อมูล ไม่ใช่สิ่งที่ควรกรองทิ้งไปเงียบ ๆ ทั้งนี้เส้นทาง agent ไม่เคยเจอปัญหานี้ เพราะมันไม่ได้ค้นเลย

5 ข้อจำกัด

5.1 abstention ยังใช้งานไม่ได้

ที่ `min_score=0.45` คำถามที่ตอบไม่ได้ **1 จาก 4 ข้อ** เท่านั้นที่คืนค่าว่างได้ถูกต้อง

```
highest top-1 score among unanswerable questions: 0.578
lowest  top-1 score among answerable   questions: 0.540
```

ช่วงคะแนน**ทับกัน** ไม่มี threshold เดียวที่แยกสองกลุ่มนี้ออกจากกันได้: ยก floor ขึ้นเป็น 0.578 จะเริ่มปฏิเสธคำถามจริง ลดลงก็ตอบขยะ

การกวาดค่าพบ config หนึ่งที่สองช่วงแยกกันได้ (200/40: 0.568 เทียบกับ 0.558) — ห่างกัน 0.010 บนคำถามสี่ข้อ และ recall แย่กว่า นั่นคือ noise ไม่ใช่คำตอบ จึงรายงานไว้แทนที่จะนำมาใช้

threshold บนค่า cosine เป็นเครื่องมือที่ผิดสำหรับงานนี้ การ rerank shortlist ที่กว้างขึ้นด้วย cross-encoder หรือให้โมเดลตัดสินความเกี่ยวข้องก่อนตอบ จะเป็นการตัดสินจากเนื้อหาแทนระยะทาง

5.2 คลังข้อมูลคือข้อความที่สกัดได้ ไม่ใช่ตัวคู่มือ

มีคำถามหลายข้อถูกตัดทิ้ง เพราะคำตอบมีอยู่ในคู่มือแต่อยู่ในรูปภาพ: ผู้เล่นเริ่มด้วย action cube กี่อัน (พิมพ์อยู่บนกระดานผู้เล่น) จะเกิดอะไรขึ้นเมื่อแถวบนกระดานเต็ม (แสดงเป็นภาพ ไม่ได้เขียน) และใครได้เริ่มก่อน (อยู่ในภาพการตั้งเกม) ทั้ง vector และ BM25 ล้มเหลวทุกข้อ ซึ่งเป็นสิ่งที่แยก “ไม่มีอยู่ในคลัง” ออกจาก “retrieval หาไม่เจอ”

ไม่มีการปรับปรุง retrieval แบบใดที่เข้าถึงข้อมูลเหล่านี้ได้ ต้องใช้ตัวสกัดที่อ่านภาพได้

5.3 ชุดประเมินผลมีขนาดเล็ก และ chunk เกือบซ้ำกันข้ามไฟล์

คำถามที่ตอบได้ 20 ข้อ เพียงพอที่จะแยก 0.533 ออกจาก 0.683 แต่ไม่พอที่จะตัดสิน ความต่างระดับไม่กี่ร้อยส่วน ความต่างที่ต่ำกว่า $\sim$0.02 ในการกวาดค่าจึงถูกรายงาน ว่าเป็น noise และ bias ของการ label ในหัวข้อ 3.1 ยังคงมีอยู่บางส่วน ที่อ่อนกว่านั้นคือคำถามที่ตอบไม่ได้มีเพียง 4 ข้อ น้อยเกินกว่าจะสรุปเรื่อง abstention ได้ ทางแก้ที่ถูกที่สุดมีอยู่แล้วในรีโป คือคำถามอีก 6 ข้อใน `eval/skipped.txt` ที่ตรวจ แล้วว่าคลังไม่มีคำตอบ เลื่อนขึ้นมาเป็นกลุ่มนี้ได้โดยไม่ต้อง label เพิ่ม ตัวหารจะเป็น 10 อีกข้อจำกัดหนึ่งคือ expansion เขียนกฎของเกมหลักซ้ำมาก การ dedupe จับ chunk ที่ข้อความเกือบเหมือนกันได้ แต่จับข้อความสี่ชุดที่ ใช้ถ้อยคำต่างกัน แต่พูดกฎข้อเดียวกันไม่ได้ ซึ่งคือสิ่งที่ไปเต็มทุกช่องในหัวข้อ 4.5

6 สิ่งที่จะทำต่อ

hybrid retrieval ด้วย Reciprocal Rank Fusion หัวข้อ 4.1 คือสามเคสที่วัดได้ว่า BM25 หาเจอสิ่งที่ embedding พลาด และ BM25 ทำคะแนนได้ 0.400 ด้วยตัวเอง การรวมผลด้วยอันดับเลี่ยงปัญหาสเกลที่เทียบกัน ไม่ได้ระหว่างคะแนน BM25 กับค่า cosine นี่คือก้าวต่อไปที่คุ้มค่าที่สุด

cross-encoder reranker บน shortlist ที่กว้างขึ้น ดึงมา 20 อัน rerank แล้วเก็บ 4 อัน วิธีนี้แก้หัวข้อ 4.5 โดยตรง — ข้อยกเว้นจะต้องผ่านแค่ shortlist ไม่ใช่ต้องติด top-4 — และแก้หัวข้อ 5.1 ด้วย เพราะ reranker ตัดสินจากเนื้อหาไม่ใช่ระยะทาง

เทียบผลรายคำถามระหว่าง config การกวาดค่ารายงานเป็นค่าเฉลี่ย ซึ่งเป็นเหตุผลที่หัวข้อ 4.5 หลุดรอดไปได้ การแสดงว่าการเปลี่ยนแต่ละครั้ง ทำพัง คำถามข้อไหนบ้าง ไม่ใช่แค่ค่าเฉลี่ยที่ขยับ จะทำให้จับเรื่องนี้ได้ตั้งแต่ตอนกวาดค่า แทนที่จะมาเจอตอน demo

อีกสองอย่างที่เล็กกว่าแต่มีหลักฐานรองรับแล้วเช่นกัน คือการกรองด้วย metadata ตามแหล่งที่มา เพื่อไม่ให้คำถามเรื่องกฎหลักต้องแข่งกับ chunk ของ Asia (หัวข้อ 4.2) ซึ่ง retriever รองรับการกรองด้วย `game` อยู่แล้ว และการทำความสะอาดคลังข้อมูลตอน ingest เพื่อตัดชื่อไฟล์ `.indd` เวลา export และเศษข้อความการ์ดนกที่ถูก index ราวกับว่าเป็นกฎออกไป (หัวข้อ 4.6)

ภาคผนวก A การทำซ้ำทั้งหมด

```
cp .env.example .env ; uv sync --extra dev ; uv run pytest   # 76 tests, offline
uv run --env-file .env python scripts/ingest.py            # build the index
uv run --env-file .env python -m eval.run_eval             # section 3.4
uv run --env-file .env python scripts/sweep_chunking.py    # section 3.5
uv run --env-file .env python scripts/demo.py              # section 4
```

ไฟล์ประกอบในรีโป โฟลเดอร์ `eval/` มีชุดคำถาม 24 ข้อที่ label แล้ว (`eval_set.json`), ผลการวัดฉบับเต็ม (`RESULTS.md`, `CHUNKING.md`), หัวข้อ 4 ฉบับเต็ม (`FAILURE_CASES.md`), บันทึกการรัน demo (`TRANSCRIPT.md`) และคำถามที่ตัดทิ้งระหว่าง label (`skipped.txt`) **การตั้งค่า** `gemma-4-E4B-it` (chat), `bge-m3` (embeddings), `temperature=0`, chunk 450/90, `top_k=4`, `min_score=0.45`, API key จาก environment